Formularium Statistiek

2. Basisbegrippen & kansrekenen

Bernoulli-verdeling. $B(\pi) = \pi^x(1-\pi)^{1-x}$. π = kans op succes. $E[X] = \pi$; $\mathrm{Var}(X) = \pi(1-\pi)$.

Verwachte waarde (discreet). $E[X] = \sum_{x\in\Omega} x P(X = x)$.

Variantie (discreet). $\mathrm{Var}(X) = \sum_{x\in\Omega}(x - E[X])^2 P(X = x)$.

Verwachte waarde (continu). $E[X] = \displaystyle\int_{x\in\Omega} x f(x)\,dx$.

Variantie (continu). $\mathrm{Var}(X) = \displaystyle\int_{x\in\Omega} (x - E[X])^2 f(x)\,dx$.

Normale dichtheid. $f(x) = \dfrac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$, $X \sim N(\mu, \sigma^2)$. $E[X] = \mu$; $\mathrm{Var}(X) = \sigma^2$.

68%-95% regel. $P(\mu - \sigma < X < \mu + \sigma) \approx 0.68$; $P(\mu - 2\sigma < X < \mu + 2\sigma) \approx 0.95$.

Standaardisatie. $Z = \dfrac{X - \mu}{\sigma} \sim N(0, 1)$.

Kans via standaardisatie. $P(a \le X \le b) = \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)$; $\Phi(-z) = 1 - \Phi(z)$.

Kwantiel z_α (= $(1-\alpha)\cdot 100\%$-percentiel). $P(Z \ge z_\alpha) = \alpha$; $P(-z_{\alpha/2} \le Z \le z_{\alpha/2}) = 1 - \alpha$.

Referentie-interval. $[\mu - z_{\alpha/2}\sigma,\ \mu + z_{\alpha/2}\sigma]$; geschat: $[\bar{x} - z_{\alpha/2}s_x,\ \bar{x} + z_{\alpha/2}s_x]$.

ECDF. $\widehat{F}(x) = \dfrac{\#(x_i \le x)}{n}$.

Steekproefgemiddelde. $\bar{X} = \dfrac{1}{n}\sum_{i=1}^n X_i$.

Notatie: populatie μ, σ^2 (Grieks) $\leftrightarrow$ steekproef $\bar{X}, S^2$ (Latijns).

4. Data-exploratie & beschrijvende statistiek

Steekproefgemiddelde. $\bar{x} = \dfrac{1}{n}\sum_{i=1}^n x_i$.

Geometrisch gemiddelde. $\sqrt[n]{\prod_i x_i} = \exp\{\frac{1}{n}\sum_i \log x_i\}$.

Log fold change. $\log B - \log A = \log(FC_{B \text{ vs } A})$.

Steekproefvariantie. $s_x^2 = \dfrac{\sum_i (x_i - \bar{x})^2}{n-1}$; $s_x = \sqrt{s_x^2}$.

Lineaire transformatie. $\mathrm{Var}(aX) = a^2\mathrm{Var}(X)$; $SD(aX) = |a|SD(X)$; $\mathrm{Var}(X + a) = \mathrm{Var}(X)$.

Bereik / IQR. $R_x = x_{\max} - x_{\min}$; $IQR = x_{75} - x_{25}$.

Variatiecoëfficiënt. $VC_x = \dfrac{s_x}{\bar{x}} \times 100\%$.

Covariantie. $\mathrm{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])]$.

Correlatie (Pearson, steekproef). $\mathrm{cor}(x, y) = \dfrac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{(n-1)s_x s_y} \in [-1, 1]$.

Risico/odds (kwalitatieve associatie). $ARV = p_T - p_C$; $RR = \dfrac{p_T}{p_C}$; odds $= \dfrac{p}{1-p}$; $OR = \dfrac{\text{odds}_T}{\text{odds}_C}$. Bij zeldzame uitkomst ($p < 5\%$): $OR \approx RR$.

5. Statistische besluitvorming

Var./SE van het gemiddelde. $\mathrm{Var}(\bar{X}) = \dfrac{\sigma^2}{n}$; $SE(\bar{X}) = \dfrac{\sigma}{\sqrt{n}}$; geschat: $\widehat{SE} = \dfrac{S}{\sqrt{n}}$.

Var. van lin. combinatie. $\mathrm{Var}(aX + bY) = a^2\mathrm{Var}(X) + b^2\mathrm{Var}(Y) + 2ab\,\mathrm{Cor}(X, Y)\sqrt{\mathrm{Var}(X)\mathrm{Var}(Y)}$.

Centrale limietstelling. $\bar{X}_n \approx N\left(\mu, \frac{\sigma^2}{n}\right)$ voor grote n, ongeacht verdeling van X_i.

BI gemiddelde, gekende σ. $\left[\bar{X} - z_{\alpha/2}\frac{\sigma}{\sqrt{n}},\ \bar{X} + z_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right]$.

t-verdeling. $\dfrac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$.

BI gemiddelde, ongekende σ. $\left[\bar{X} - t_{n-1,\alpha/2}\frac{s}{\sqrt{n}},\ \bar{X} + t_{n-1,\alpha/2}\frac{s}{\sqrt{n}}\right]$.

One-sample t-test. $H_0 : \mu = \mu_0$; $t = \dfrac{\bar{X} - \mu_0}{se_{\bar{X}}} \sim t_{n-1}$ onder H_0.

p-waarde. Eenzijdig ($H_1 : \mu > \mu_0$): $p = P_0[T \ge t]$. Eenzijdig ($H_1 : \mu < \mu_0$): $p = P_0[T \le t]$. Tweezijdig ($H_1 : \mu \ne \mu_0$): $p = 2P_0[T \ge |t|]$.

Kritieke waarde / beslissing. Verwerp H_0 als $|t| > t_{n-1;\alpha/2}$ (tweezijdig).

Type I/II fout, power. $P[\text{Type I}] = \alpha$; power $\pi(\delta) = 1 - \beta(\delta) = P_\delta[P < \alpha]$.

Gepaarde t-test. $\bar{X} = \sum_i \frac{Y_{i2} - Y_{i1}}{n}$; toets = one-sample t-test op de verschillen.

Two-sample model. $Y_{ij} \sim N(\mu_j, \sigma^2)$, $i = 1, \ldots, n_j$, $j = 1, 2$.

Gepoolde variantie. $S_p^2 = \dfrac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$.

Two-sample t-test (gelijke var.). $T = \dfrac{\bar{Y}_1 - \bar{Y}_2}{S_p\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1+n_2-2}$; BI: $(\bar{Y}_1 - \bar{Y}_2) \pm t_{n_1+n_2-2,\alpha/2} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$.

Welch t-test (ongelijke var.). $T = \dfrac{\bar{Y}_1 - \bar{Y}_2}{\sqrt{S_1^2/n_1 + S_2^2/n_2}}$.

6. Lineaire regressie (enkelvoudig)

Model. $Y = \beta_0 + \beta_1 x + \epsilon$, $\epsilon \sim N(0, \sigma^2)$; $E[Y \mid X{=}x{+}\delta] - E[Y \mid X{=}x] = \beta_1\delta$.

KKS-schatters. $\hat{\beta}_1 = \dfrac{\sum_i (y_i - \bar{y})(x_i - \bar{x})}{\sum_i (x_i - \bar{x})^2} = \dfrac{\mathrm{cor}(x, y)s_y}{s_x}$; $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}$.

MSE. $\hat{\sigma}^2 = \mathrm{MSE} = \dfrac{\sum_i e_i^2}{n-2}$, $e_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$.

SE van schatters. $SE_{\hat{\beta}_1} = \sqrt{\dfrac{\mathrm{MSE}}{\sum_i (X_i - \bar{X})^2}}$; $SE_{\hat{\beta}_0} = \sqrt{\dfrac{\sum_i X_i^2}{\sum_i (X_i - \bar{X})^2} \cdot \dfrac{\mathrm{MSE}}{n}}$.

Toets/BI helling. $T = \dfrac{\hat{\beta}_1 - \beta_1}{SE_{\hat{\beta}_1}} \sim t_{n-2}$; BI: $\hat{\beta}_1 \pm t_{n-2,\alpha/2} SE_{\hat{\beta}_1}$; $H_0 : \beta_1 = 0$.

BI gemiddelde respons. $SE_{\hat{g}(x)} = \sqrt{\mathrm{MSE}\left\{\frac{1}{n} + \frac{(x - \bar{X})^2}{\sum_i (X_i - \bar{X})^2}\right\}}$.

Predictie-interval. $SE_{\hat{Y}(x)} = \sqrt{\mathrm{MSE}\left\{1 + \frac{1}{n} + \frac{(x - \bar{X})^2}{\sum_i (X_i - \bar{X})^2}\right\}}$ (groter dan BI door extra term 1).

Kwadratensommen. $\mathrm{SSTot} = \sum_i (Y_i - \bar{Y})^2$; $\mathrm{SSR} = \sum_i (\hat{Y}_i - \bar{Y})^2$; $\mathrm{SSE} = \sum_i (Y_i - \hat{Y}_i)^2$; $\mathrm{SSTot} = \mathrm{SSR} + \mathrm{SSE}$.

R^2 en F-test. $R^2 = 1 - \dfrac{\mathrm{SSE}}{\mathrm{SSTot}} = \dfrac{\mathrm{SSR}}{\mathrm{SSTot}}$; $F = \dfrac{\mathrm{SSR}/1}{\mathrm{SSE}/(n-2)} \sim F_{1,n-2}$ onder $H_0 : \beta_1 = 0$.

Dummy-variabele (2 groepen). $Y = \beta_0 + \beta_1 x + \epsilon$, $x \in \{0, 1\}$; $\beta_1 = \mu_2 - \mu_1$; $\hat{\beta}_0 = \bar{Y}_1$, $\hat{\beta}_1 = \bar{Y}_2 - \bar{Y}_1$ (= two-sample t-test).

Polynomiale regressie. $E(Y \mid X) = \beta_0 + \beta_1 X + \beta_2 X^2 (+\beta_3 X^3 + \ldots)$.

7. Variantie-analyse (ANOVA)

Model. $Y_i \mid \text{groep } j \sim N(\mu_j, \sigma^2)$; $H_0 : \mu_1 = ... = \mu_g$.

Kwadratensommen. $\text{SST} = \sum_j n_j(\bar{Y}_j - \bar{Y})^2$ (tussen groepen, $g-1$ df); $\text{SSTot} = \text{SST} + \text{SSE}$; $\text{MSE} = \sum_j \frac{(n_j-1)S_j^2}{n-g}$.

F-test. $F = \dfrac{\text{SST}/(g-1)}{\text{SSE}/(n-g)} = \dfrac{\text{MST}}{\text{MSE}} \sim F_{g-1,n-g}$.

Post-hoc t-test. $T_{jk} = \dfrac{\bar{Y}_j - \bar{Y}_k}{\sqrt{\text{MSE}\left(\frac{1}{n_j} + \frac{1}{n_k}\right)}} \sim t_{n-g}$.

Bonferroni. $\alpha_E \leq m\alpha$ (FWER, m toetsen); individueel niveau $\alpha = \alpha_E/m$; aangepaste p-waarde $\tilde{p} = \min(mp, 1)$.

One-sample t-test als lineair model. $Y_i \sim N(\beta_0, \sigma^2)$; $\hat{\mu} = \hat{\beta}_0$; $T = \dfrac{\hat{\beta}_0 - \beta_0}{SE_{\hat{\beta}_0}} \sim t_{n-1}$.

Two-sample t-test als lineair model. $Y_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$, $x_i = 1$ in groep 2 ($x_i = 0$ in groep 1); $\hat{\mu}_2 - \hat{\mu}_1 = \hat{\beta}_1$ (zie Dummy-variabele, §6).

Contrast-test (ANOVA/GLM via lineair model). Voor een lineaire combinatie $L\beta$ (bv. $L\hat{\beta} = \hat{\beta}_4 - \hat{\beta}_2$): $T = \dfrac{L\hat{\beta} - L\beta}{SE_{L\hat{\beta}}} \sim t_{n-p}$.

8. Niet-parametrische toetsen

Wilcoxon rank-sum / Mann-Whitney. $S_1 = \sum_i R(Y_{i1})$; $U_1 = S_1 - \frac{1}{2}n_1(n_1+1) = \sum_{i,k} \mathbb{1}\{Y_{i1} \geq Y_{k2}\}$; $\frac{1}{n_1 n_2} E[U_1] = P[Y_1 \geq Y_2]$.

9. Categorische data & logistische regressie

Proportie. $\hat{\pi} = \bar{X} = \frac{1}{n}\sum_i X_i$; $SE = \sqrt{\frac{\bar{x}(1-\bar{x})}{n}}$; BI: $\bar{x} \pm z_{\alpha/2} SE$.

z-toets voor proportie. $H_0 : \pi = \pi_0$; $z = \dfrac{\bar{x} - \pi_0}{\sqrt{\pi_0(1-\pi_0)/n}}$.

Binomiale verdeling. $P(S = k) = \binom{n}{k}\pi^k(1-\pi)^{n-k}$.

Binomiale toets (exact, voor π). $H_0 : \pi = \pi_0$; x = aantal successen, n = aantal onafh. observaties, $p = \pi_0$.

Gepaarde data (McNemar). $\widehat{ARV} = \dfrac{f-g}{n}$, $SE = \frac{1}{n}\sqrt{f+g-\frac{(f-g)^2}{n}}$; $z = \dfrac{f-g}{\sqrt{f+g}}$ (met continuïteitscorrectie: $z = \dfrac{|f-g|-1}{\sqrt{f+g}}$); f, g = discordante paren. Exact (bij kleine f, g): binomiale toets met $x = f$, $n = f+g$, $\pi_0 = 0.5$.

Chi-kwadraattoets. $E_{ij} = \dfrac{\text{rijtot}_i \cdot \text{koltot}_j}{n}$; $X^2 = \sum_{ij} \dfrac{(O_{ij} - E_{ij})^2}{E_{ij}} \sim \chi^2_{(r-1)(c-1)}$ (2×2 met Yates-correctie: -0.5 in teller).

Logistische regressie. $Y_i \sim B(\pi_i)$, $\log \dfrac{\pi_i}{1-\pi_i} = \beta_0 + \beta_1 X_{i1} + ... + \beta_p X_{ip}$.

Categorisch: intercept $= \log \text{ODDS}_{\text{ref}}$; $\beta_k = \log \dfrac{\text{ODDS}_k}{\text{ODDS}_{\text{ref}}}$ (log-OR t.o.v. referentie).

Continu: $\exp(\beta_1) = \text{OR}$ per eenheid verschil in x.

10. Algemeen lineair model

Additief model. $Y_i = \beta_0 + \beta_1 X_{i1} + ... + \beta_{p-1} X_{i,p-1} + \epsilon_i$, $\epsilon_i \sim N(0, \sigma^2)$.

Interpretatie β_j. $E(Y \mid ..., X_j = x_j + \delta, ...) - E(Y \mid ..., X_j = x_j, ...) = \beta_j \delta$ (overige X_k constant).

MSE. $\hat{\sigma}^2 = \text{MSE} = \dfrac{\sum_i e_i^2}{n-p}$.

Toets/BI parameter. $T_k = \dfrac{\hat{\beta}_k - \beta_k}{SE(\hat{\beta}_k)} \sim t_{n-p}$; BI: $\hat{\beta}_j \pm t_{n-p,\alpha/2} SE_{\hat{\beta}_j}$.

Interactie (dummy × continu). $Y = \beta_0 + \beta_v x_v + \beta_w x_w + \beta_s x_s + \beta_{vs} x_v x_s + \beta_{ws} x_w x_s + \epsilon$; geïmpliceerde rechten: $x_s = 0$: $Y = \beta_0 + \beta_v x_v + \beta_w x_w + \epsilon$; $x_s = 1$: $Y = (\beta_0 + \beta_s) + (\beta_v + \beta_{vs}) x_v + (\beta_w + \beta_{ws}) x_w + \epsilon$.

Interactie (2 continue). $Y = \beta_0 + \beta_v x_v + \beta_w x_w + \beta_{vw} x_v x_w + \epsilon$; effect van +1 op X_v: $\beta_v + \beta_{vw} x_w$.

Factoriële proefopzet (2 factoren, interactie). $Y_i = \beta_0 + \sum_k \beta_{A_k} x_{iA_k} + \sum_l \beta_{B_l} x_{iB_l} + \sum_{k,l} \beta_{A_k:B_l} x_{iA_k} x_{iB_l} + \epsilon_i$, met x_{A_k}, x_{B_l} dummy's voor niveaus k van factor A en l van factor B (t.o.v. referentieniveaus). Niet-significante interactie (partiële F-test, zie lager) ⇒ verwijderen ⇒ additief model (hoofdeffecten apart interpreteerbaar).

VIF. $\text{VIF}_j = (1 - R_j^2)^{-1}$, met R_j^2 = determinatiecoëfficiënt van de regressie van predictor x_j op alle andere predictoren (> 10: ernstige multicollineariteit).

Leverage. Maat voor de afstand van de predictorwaarden van observatie i tot het gemiddelde; ligt tussen $1/n$ en 1, gemiddeld p/n; extreem als $> 2p/n$.

Cook's distance. $D_i = \dfrac{\sum_j (\hat{Y}_j - \hat{Y}_{j(i)})^2}{p \cdot \text{MSE}}$; extreem als D_i het 50%-percentiel van de $F_{p,n-p}$-verdeling overschrijdt.

DFBETAS. $\text{DFBETAS}_{j(i)} = \dfrac{\hat{\beta}_j - \hat{\beta}_{j(i)}}{SD(\hat{\beta}_j)}$.

Kwadratensommen & R^2/F. Zoals §6, met $p-1$ i.p.v. 1 df: $F = \text{MSR}/\text{MSE} \sim F_{p-1,n-p}$.

Extra kwadratensom (partiële F-test). $\text{SSR}_{2|1} = \text{SSE}_1 - \text{SSE}_2 = \text{SSR}_2 - \text{SSR}_1$ (model 1 = genest in model 2); $F = \dfrac{\text{SSR}_{2|1}/(\#\text{extra param.})}{\text{MSE}_2}$.

Type III kwadratensom. $\text{SSR}_{j|\text{alle andere}} = \text{SSE}_{\text{zonder } x_j} - \text{SSE}_{\text{vol}}$ (volgorde-onafhankelijk); $F = \text{MSR}_j/\text{MSE} \sim F_{1,n-p}$.